



NOME DO ROBÔ	DEJAVÚ BOT
ESTRATÉGIA	TRADE
CLASSE ATIVOS	AÇÕES
UNIVERSO	B3
MÉDIA TRADES	DIÁRIO
HOLDING PERIOD	DIÁRIO
SOFTWARE	PYTHON
BENCHMARK	B&H e SELIC

SOBRE DEJAVÚ

O **Dejavú-Bot** foi desenvolvido com o intuito de aplicar deep learning ao mercado financeiro, visando capitalizar sobre movimentos de ativos e identificar tendências de curto prazo. A estratégia emprega redes LSTM (Long Short-Term Memory), uma estrutura avançada de redes neurais conhecida por sua capacidade de reter informações sequenciais e capturar padrões complexos nos dados temporais. A LSTM é especialmente útil em mercados financeiros devido à natureza não linear e altamente volátil das séries temporais financeiras, onde eventos passados podem ter relevância significativa para movimentos futuros.

O principal objetivo do Dejavú-Bot é proporcionar uma análise de dados precisa e fundamentada, permitindo a geração de sinais de compra e venda com o intuito de maximizar o retorno ajustado ao risco em operações de curto prazo. Diferentemente de abordagens tradicionais, o uso de LSTM permite ao modelo “lembrar” informações cruciais ao longo do tempo, o que pode auxiliar na diferenciação entre movimentos genuínos de tendência e ruídos de mercado. Esse aspecto é de grande valor, especialmente em mercados emergentes como o brasileiro, que são altamente influenciados por fatores externos, tais como mudanças políticas e econômicas.

Ao adotar uma abordagem baseada em LSTM, o Dejavú-Bot busca também evitar os erros comuns em modelos como médias móveis e regressão linear, que muitas vezes falham em capturar a complexidade das séries temporais. Em contraste, o modelo LSTM é projetado para tratar diretamente com dados sequenciais, o que, em teoria, permite uma análise mais robusta e informada para tomadas de decisão de trading. Dessa forma, o Dejavú-Bot se apresenta como uma solução atualizada e tecnicamente avançada para investidores que desejam explorar o potencial da inteligência artificial em suas operações financeiras.

ESTRATÉGIA DE INVESTIMENTO

A estratégia de investimento do Dejavú-Bot baseia-se na identificação do *momentum* dos ativos, com o objetivo de prever a direção futura do preço e, com isso, gerar sinais de compra e venda. A regra de investimento foi desenhada para capturar movimentos favoráveis de preço, aproveitando a capacidade do modelo de identificar tendências emergentes. Os componentes dessa estratégia incluem:

- Sinal de Compra:** Um sinal de compra é acionado quando o modelo prevê que o preço do ativo aumentará no próximo dia, em comparação com o preço previsto do dia anterior. Esse sinal representa uma entrada estratégica, sugerindo que o investidor adote uma posição comprada antes que a alta se consolide.
- Sinal de Venda:** Quando a previsão do modelo indica uma queda de preço no próximo dia, um sinal de venda é gerado. Esse sinal visa proteger o investidor contra perdas iminentes, recomendando a saída antes que a tendência de baixa se torne significativa.

O sistema foi projetado para capturar os movimentos mais seguros dentro do ciclo de preço, com o intuito de maximizar o potencial de lucro em cada transação. A janela de tempo de 60 dias para as previsões foi escolhida após uma série de testes empíricos, demonstrando um equilíbrio ideal entre sensibilidade e robustez do modelo, sendo suficiente para capturar padrões de recuperação e retração no preço dos ativos.

BASES DE DADOS

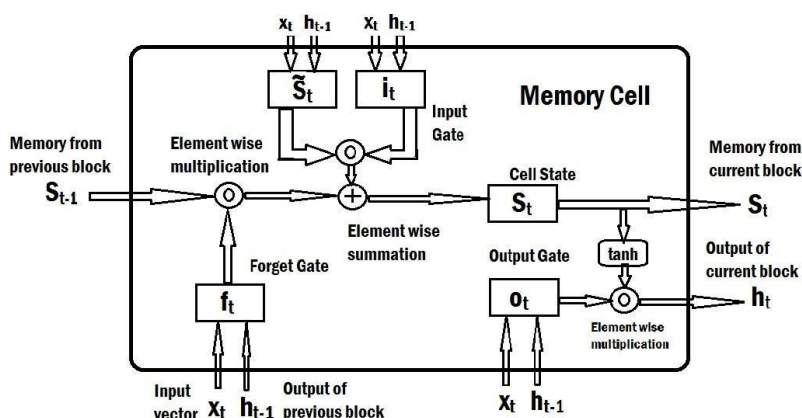
Os dados históricos utilizados pelo Dejavú-Bot foram coletados a partir do Yahoo Finance, abrangendo o período de 2010 a 2020. Este intervalo inclui diversos ciclos econômicos e eventos de mercado, permitindo que o modelo aprenda com uma ampla variedade de cenários e ganhe uma perspectiva robusta sobre as dinâmicas de mercado. Para garantir a precisão do modelo, os dados passaram por um processo rigoroso de pré-processamento. Apenas os preços ajustados dos ativos foram utilizados, removendo influências externas, como dividendos e ajustes corporativos, que poderiam distorcer a análise. Os dados foram então normalizados para garantir uma convergência estável e prevenir problemas numéricos comuns em deep learning. A divisão dos dados entre treino e teste foi realizada em uma proporção de 50%, o que proporcionou uma base sólida para o treinamento e uma validação adequada em um conjunto de teste igualmente extenso.

MODELAGEM

A arquitetura do modelo LSTM empregada pelo Dejavú-Bot consiste em duas camadas de LSTM seguidas por uma camada densa de saída. A estrutura do modelo foi projetada para maximizar a capacidade de generalização e capturar padrões complexos presentes nos dados temporais:

- **Camada de Entrada:** Recebe uma sequência de 60 dias de preços normalizados e a repassa para a primeira camada LSTM.
- **Primeira Camada LSTM:** Com 50 unidades e um dropout de 20%, essa camada é configurada para retornar uma sequência completa, permitindo que as informações temporais sejam transmitidas à próxima camada LSTM. Esta camada inicial detecta correlações temporais iniciais.
- **Segunda Camada LSTM:** Configurada para retornar uma única previsão, esta camada extrai as características finais da sequência e gera uma previsão de preço. Um dropout adicional de 20% é aplicado para reduzir o risco de overfitting e melhorar a capacidade do modelo de generalizar para novos dados.
- **Camada de Saída:** Um único neurônio denso que retorna o valor previsto, ajustado para a escala normalizada.

O modelo foi treinado utilizando o otimizador Adam, reconhecido por sua estabilidade e adaptabilidade em problemas de regressão. A função de perda utilizada foi o Mean Squared Error (MSE), adequada para minimizar desvios entre os preços previstos e os preços reais. Este conjunto de escolhas foi projetado para garantir que o modelo pudesse ajustar-se de maneira precisa, sem criar uma dependência excessiva dos dados de treino.




BACKTEST E RESULTADOS

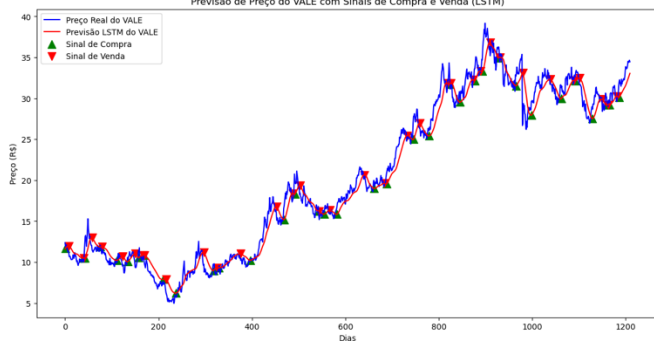
Para avaliar a estratégia, foi realizado um backtest utilizando o conjunto de teste, onde os sinais de compra e venda foram gerados com base nas previsões do modelo LSTM. Iniciando com um capital de R\$100,00, cada transação atualizava o capital acumulado com o ganho ou perda percentual obtido na operação, criando assim um histórico acumulado de performance. Essa abordagem possibilitou a criação de um cenário simulado, representando a performance potencial da estratégia em um contexto real. O backtest aplicado à estratégia de LSTM para ações brasileiras Vale, Itaú, Petrobras e AMBEV revelou algumas observações importantes sobre a performance do modelo.

Os gráficos de backtest e o gráfico de retorno acumulado evidenciam que, embora o modelo tenha sido capaz de capturar certos movimentos de curto prazo, seu desempenho ficou abaixo da estratégia de “buy and hold” para dois dos quatro ativos analisados. A estratégia de LSTM gerou retornos moderados, mas foi menos eficaz em capturar o crescimento sustentado dos ativos ao longo do tempo. Observa-se que, em muitos casos, os sinais de compra e venda ocorreram durante pequenas oscilações, resultando em operações pouco lucrativas e, por vezes, em perdas potenciais. A estratégia “buy and hold” destacou-se como mais robusta e eficaz para o período analisado, principalmente devido ao crescimento de longo prazo dos ativos e à capacidade de capturar ciclos completos de valorização. Esse resultado sugere que o foco excessivo do modelo em movimentos de curto prazo o impediu de aproveitar o crescimento acumulado dos ativos.


A estratégia baseada em LSTM apresentou algumas limitações que impactaram seu desempenho: (1) Sensibilidade a Ruídos, por ser sensível a pequenas flutuações, interpretou certos movimentos como tendência; (2) Overfitting onde pode ter se ajustado excessivamente aos padrões históricos e (3) Ausência de Fatores Fundamentais que poderiam proporcionar um contexto mais abrangente para a previsão de preços.




Previsão de Preço do VALE com Sinais de Compra e Venda (LSTM)




Previsão de Preço do ITUB4.SA com Sinais de Compra e Venda (LSTM)



Previsão de Preço do PETR4.SA com Sinais de Compra e Venda (LSTM)



Previsão de Preço do ABEV3.SA com Sinais de Compra e Venda (LSTM)



Entretanto, a análise dos retornos anuais da estratégia LSTM para as ações em comparação com a taxa SELIC entre 2015 e 2019 revela algumas características marcantes da abordagem. Em anos de recuperação do mercado, como 2016, a estratégia LSTM conseguiu capturar de forma eficaz a alta, gerando retornos expressivos para ativos como VALE3 e PETR4, que superaram amplamente o rendimento da SELIC. Esse desempenho ilustra o potencial da estratégia em períodos de crescimento, onde o modelo LSTM identificou corretamente as tendências de alta e gerou sinais de compra vantajosos para os investidores.

Por outro lado, em anos de maior instabilidade, como 2015, a estratégia apresentou dificuldades, resultando em perdas significativas para a maioria dos ativos, enquanto a SELIC ofereceu um rendimento seguro de 14.25%. Essa disparidade destaca uma fragilidade da estratégia LSTM em capturar movimentos de queda ou proteger o capital em cenários adversos, sugerindo que, em momentos de alta volatilidade ou

retração do mercado, investir na SELIC teria sido uma opção mais prudente. Além disso, a estratégia demonstrou uma certa inconsistência entre os ativos: enquanto VALE3 e PETR4 tiveram um desempenho robusto na maioria dos anos, ABEV3 registrou retornos negativos em 2016 e 2018, indicando que a eficácia da LSTM pode variar conforme as características de cada ação.

Dessa forma, estratégia LSTM oferece uma oportunidade de ganhos superiores à SELIC em períodos de alta do mercado, mas apresenta limitações em anos de queda e não garante proteção em contextos de instabilidade. Para investidores com maior tolerância ao risco, a estratégia pode ser interessante, desde que estejam cientes das suas oscilações e volatilidade. No entanto, para um perfil mais conservador ou em momentos de incerteza, a SELIC se mantém como uma alternativa mais segura e estável. A estratégia LSTM, portanto, pode ser potencialmente aprimorada com ajustes que aumentem sua capacidade de identificar quedas e implementar mecanismos de gestão de risco que protejam o capital em períodos de baixa, tornando-a mais consistente e confiável no longo prazo.

CONCLUSÃO

O Dejavú-Bot e sua abordagem de LSTM demonstram uma aplicação promissora de inteligência artificial para trading de curto prazo, mas os resultados do backtest indicam que a estratégia ainda enfrenta desafios em relação ao “buy and hold” no contexto de mercados emergentes. O desempenho inferior da LSTM em comparação à estratégia conservadora sugere que, para investidores com foco em crescimento de longo prazo, abordagens mais tradicionais continuam sendo preferíveis.

Em suma, o modelo oferece um potencial interessante como ferramenta para trading automatizado, mas suas limitações em capturar o desempenho de longo prazo dos ativos sugerem que melhorias adicionais são necessárias para torná-lo uma solução mais equilibrada e eficaz. Este estudo reforça a importância de uma abordagem criteriosa no desenvolvimento de modelos baseados em LSTM, reconhecendo o valor das estratégias de “buy and hold” e a necessidade de avanços para melhorar a viabilidade de modelos de inteligência artificial em mercados de renda variável.

REFERÊNCIAS

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. **Deep Learning**. Cambridge: MIT Press, 2016.
CHEN, James; BROOKS, Chris. **Artificial Intelligence in Finance: A Python-Based Guide**. London: Palgrave Macmillan, 2023.

ANO	VALE3	ITUB4	PETR4	ABEV3	SELIC
2015	-31.55	-10.31	-20.13	3.46	14.25
2016	93.15	36.63	83.1	-7.06	13
2017	47.69	37.01	5.83	31.84	7
2018	37.48	32.74	44.4	-22.22	6.5
2019	5.52	9.57	39.96	21.26	4.5